

Rapport

Projet webscrapping

Rapport d'Analyse : Dynamiques du Marché Immobilier Français
Sujet : Facteurs de variation du prix au m² sur le territoire national.

Cours : Data Analytics / webscrapping
Université / DU Data Analyst — Sorbonne

Auteurs :

- Max Guiriec
- Saïd Mansour

Données : Fusion SeLoger & Notaires de France (520 000+ annonces).

Date : Décembre 2025

0. Introduction et Problématique :

Le marché immobilier constitue un enjeu économique et social majeur, tant pour les particuliers que pour les institutions publiques et privées. Il est fortement influencé par des facteurs macroéconomiques tels que les taux d'intérêt, l'inflation, la démographie ou encore les politiques publiques de logement.

Dans ce contexte, l'accès à des données fiables et actualisées est essentiel pour analyser les dynamiques du marché, comparer les prix, identifier les disparités territoriales et anticiper les évolutions futures.

Cependant, une grande partie des données immobilières disponibles en ligne est fragmentée entre différentes plateformes, souvent sous des formats non directement exploitables. Le web scraping apparaît alors comme une solution pertinente pour collecter, structurer et analyser ces données à grande échelle.

0.1 Objectif du projet :

L'objectif principal de ce projet est de collecter et d'analyser des données immobilières issues de différentes plateformes françaises afin de mieux comprendre les caractéristiques du marché immobilier résidentiel.

Plus précisément, ce projet vise à :

- automatiser la collecte d'annonces immobilières à partir de sites spécialisés,
- structurer les données collectées sous une forme exploitable pour l'analyse,
- comparer deux approches de web scraping reposant sur des contraintes techniques différentes,
- mettre en évidence les limites techniques, éthiques et méthodologiques du scraping de données immobilières.

Ce projet s'inscrit ainsi à la fois dans une démarche technique (web scraping, traitement de données) et analytique (exploration et compréhension du marché immobilier).

1. Stratégie de scraping :

NOTAIRES :

Contrairement à **Seloger**, ce site met à disposition un **endpoint JSON** accessible sans authentification, ce qui permet une collecte de données plus simple et plus stable.

Le scraping repose donc sur l'exploitation directe de cette API, sans nécessiter de simulation complexe du comportement navigateur.

1.1 Fonctionnement du script :

Le script parcourt l'ensemble des départements français, y compris les départements d'outre-mer.

Pour chaque département, il interroge l'API du site en utilisant une pagination par numéro de page.

À chaque requête, les annonces retournées sont analysées et les informations pertinentes sont extraites, notamment :

- le prix affiché,
- la surface du bien,
- le nombre de pièces et de chambres,
- le type de bien,
- la localisation,
- la date de mise à jour de l'annonce.

L'ensemble des annonces collectées est ensuite agrégé dans un DataFrame Pandas et exporté dans un fichier CSV unique couvrant l'ensemble du territoire français.

1.2 Difficultés rencontrées (Notaires)

Les difficultés rencontrées sont :

- Gestion de la pagination : il a fallu identifier le comportement de l'API afin de déterminer le signal indiquant la fin des pages disponibles (code HTTP ou absence de résultats).
- Qualité des données : certaines annonces ne contiennent pas toutes les informations
- Le fichier CSV final peut devenir volumineux, ce qui limite la scalabilité pour des analyses très fines ou répétées.

1. Stratégie de scraping

SCRIPT SELOGER :

Le site Seloger ne propose pas d'API publique permettant l'accès aux annonces immobilières.

Nous avons donc adopté une approche de reverse engineering des appels réseau effectués par le site web afin de reproduire les requêtes utilisées par le navigateur lors d'une recherche.

Cette approche implique une simulation du comportement utilisateur et une architecture plus complexe que pour le script Notaires.

1.3 Fonctionnement du script :

Le fonctionnement du script Seloger repose sur plusieurs étapes successives :

- Récupération des identifiants internes des départements via l'endpoint d'autocomplétion du site.
- Recherche paginée des annonces pour chaque département afin d'obtenir les identifiants des annonces.
- Extraction des informations détaillées de chaque annonce à partir de ces identifiants.
- Structuration et export des données dans des fichiers CSV par département.
- Les requêtes sont accompagnées de headers HTTP réalistes et de cookies issus d'une session navigateur réelle afin d'éviter les mécanismes de blocage automatique.

1.4 Difficultés rencontrées (Seloger)

- Absence d'API officielle, nécessitant une analyse approfondie des appels réseau du site.
- Gestion des cookies et des protections anti-bot, avec une dépendance à des sessions navigateur valides.
- Fragilité des endpoints, qui peuvent évoluer sans préavis.
- Temps d'exécution élevé, en raison de la pagination et du volume d'annonces par département.

2. Préparation des Données (Data Engineering)

2.1. Ingestion et Fusion Multi-Sources :

Le projet repose sur l'unification de deux bases hétérogènes : les annonces de l'offre (SeLoger) et celles de (Notaires de France).

- Défis techniques : Développement d'un script Python pour la détection dynamique des séparateurs CSV et l'harmonisation des colonnes (ex: unification des labels "price" et "prix").
- Volume : Après extraction des codes départements depuis les noms de fichiers, le dataset consolidé contient plus de 520 000 lignes au format Parquet.
- Dédoublonnage : Suppression des annonces redondantes via l'identifiant unique id.

2.2. Traitement des Valeurs Aberrantes (Outliers)

Pour ne conserver que le marché résidentiel standard, des seuils de cohérence ont été appliqués :

- Surfaces : Exclusion des biens $> 500 \text{ m}^2$.
- Prix : Plafonnement à 5 000 000 € pour écarter l'immobilier d'ultra-luxe.
- Structure : Élimination des anomalies sur le nombre de pièces (> 20) ou de chambres (> 15).

2.3. Harmonisation et Typologie

Les nomenclatures sources étant disparates (ex: "HOUSE" vs "MAI"), un moteur de mapping a normalisé les données en 6 catégories claires : Maison, Appartement, Terrain, Immeuble, Local commercial et Garage.

3. Analyse Descriptive : Les Leviers de Variation

C'est ici que nous répondons visuellement à la problématique.


3.1. L'influence du type de bien et de la surface :

L'analyse montre une corrélation inverse entre la surface et le prix au m².

- **Le paradoxe des petites surfaces** : Les studios présentent le prix au m² le plus élevé en raison de la forte demande locative et des frais fixes incompressibles.
- **Segment Appartement vs Maison** : En moyenne, le prix au m² des appartements dépasse celui des maisons, le parc d'appartements étant concentré dans les centres-villes où le foncier est rare.


3.2. Analyse des corrélations :

La matrice de corrélation révèle que **le prix total** est fortement lié à **la surface** (logique), mais que le **prix au m²** est plus sensible à la **localisation** qu'au nombre de chambres.




3. Analyse Descriptive : Les Leviers de Variation

Prix médian au m² en fonction du nombre de pièces



Prix moyen au m² par type de bien en France



4. Analyse Spatiale : La Géographie comme Premier Facteur

La localisation est le critère "numéro 1" de la valorisation immobilière.

4.1. Disparités Départementales :


La carte choroplèthe de la France met en évidence trois zones de tension :


- L'Île-de-France : Une bulle de prix exceptionnelle.
- L'Arc Méditerranéen : Une prime à l'ensoleillement et à la proximité côtière.
- Les zones frontalières (Savoie/Suisse) : Un effet d'entraînement par les salaires étrangers.

4.2. Focus : Le cas exceptionnel de Paris (75)


Paris fonctionne comme un micro-marché déconnecté du reste de la France.

- **Internalisation** : Nous avons analysé les prix par arrondissement. Les arrondissements centraux (1er, 6e, 7e) franchissent des paliers inaccessibles au reste de l'Île-de-France.
- **Fracture Paris/Banlieue** : Le prix moyen chute de plus de **40%** dès que l'on franchit le périphérique (hors 92).





Comparaison du prix/m² : Paris vs Île-de-France



5. Modélisation Prédictive (Machine Learning)

Pour valider nos analyses, nous avons développé un modèle capable d'estimer le prix au m².

5.1 Architecture du modèle :

Nous avons utilisé l'algorithme Random Forest Regressor (Forêt Aléatoire) intégré dans un Pipeline de traitement automatisé :

- Variables d'entrée (Features) : Surface, nombre de pièces, type de bien et coordonnées géographiques précises (Latitude/Longitude).
- Traitement des données : Les variables textuelles (type de bien) ont été encodées numériquement via un OneHotEncoder.
- Configuration : Le modèle combine 300 arbres de décision pour capturer les relations complexes et non-linéaires du marché (ex: l'effet de quartier).

5.2 Performance et Validation :

Le dataset a été scindé en deux : 80% pour l'apprentissage et 20% pour le test (évaluation sur des données inconnues).

Indicateurs de succès :

- MAE (Mean Absolute Error) : Mesure l'écart moyen entre le prix réel et la prédiction. Elle représente la précision "monétaire" du modèle.
- R² (Coefficient de détermination) : Indique le pourcentage de la variation des prix expliqué par le modèle. Un score proche de 1 valide la pertinence de nos variables.

5.3 Enseignement majeur :

L'importance des variables montre que la géolocalisation est le facteur prédominant. La capacité du modèle à "apprendre" les prix selon les coordonnées GPS confirme que l'adresse exacte surpasse les caractéristiques physiques du bien (surface, pièces) dans la hiérarchie de la valeur immobilière.

```

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import OneHotEncoder
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.metrics import mean_absolute_error, r2_score
from sklearn.ensemble import RandomForestRegressor

# =====
# VARIABLES
# =====

features = ["surface", "nb_pieces", "type_bien", "latitude", "longitude"]
target = "prix_m2"

df_model = df_geo_merged.dropna(subset=features + [target])

X = df_model[features]
y = df_model[target]

# =====
# TRAITEMENT CATEGORIEL
# =====

categorical_cols = ["type_bien"]
numeric_cols = ["surface", "nb_pieces", "latitude", "longitude"]

preprocess = ColumnTransformer(
    transformers=[
        ("cat", OneHotEncoder(handle_unknown="ignore"), categorical_cols),
        ("num", "passthrough", numeric_cols),
    ]
)

# =====
# MODELE
# =====

model = Pipeline(steps=[
    ("preprocessing", preprocess),
    ("regression", RandomForestRegressor(
        n_estimators=300,
        max_depth=20,
        random_state=42
    ))
])

# =====
# TRAIN / TEST
# =====

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

model.fit(X_train, y_train)
y_pred = model.predict(X_test)

# =====
# EVALUATION
# =====

print("MAE :", round(mean_absolute_error(y_test, y_pred), 2))
print("R² :", round(r2_score(y_test, y_pred), 3))

```

6. Limites du projet :

6.1 Fiabilité des données et biais potentiels

Les données collectées dans le cadre de ce projet proviennent d'annonces immobilières publiées en ligne. À ce titre, elles ne représentent pas nécessairement l'ensemble du marché immobilier réel, mais uniquement la partie visible à travers les plateformes étudiées.

- Un premier biais concerne la nature déclarative des annonces. Les informations telles que le prix, la surface ou le nombre de pièces sont fournies par les annonceurs et peuvent contenir des approximations, des erreurs ou des omissions. Certaines annonces ne renseignent pas l'ensemble des champs, ce qui peut affecter la qualité de certaines analyses, notamment celles reposant sur le calcul du prix au mètre carré.
- Un second biais est lié à la représentativité géographique et sociale des plateformes. Le site immobilier.notaires.fr reflète davantage les transactions issues du réseau notarial, tandis que Seloger est une plateforme commerciale largement utilisée par des agences immobilières. Les types de biens et les segments de marché représentés peuvent donc différer entre les deux sources, rendant les comparaisons directes parfois délicates.
- Enfin, le caractère dynamique des annonces constitue une limite importante. Les données collectées correspondent à un instant donné et ne tiennent pas compte de la durée de publication des annonces ni de leur issue réelle (vente effective, retrait, modification du prix).

6. Limites du projet :

5.2 Limites techniques du scraping

Sur le plan technique, les deux scripts présentent des limites distinctes.

Pour le site **immobilier.notaires.fr**, bien que l'accès aux données soit relativement stable, le niveau de détail des informations disponibles reste limité par rapport aux plateformes commerciales. De plus, l'absence de mécanisme de temporisation entre les requêtes pourrait poser problème dans un contexte de collecte intensive.

Concernant **Seloger**, les limites sont plus marquées. Le script repose sur des **endpoints** internes et sur l'utilisation de **cookies** issus d'une session navigateur réelle. Cette dépendance rend le processus fragile, car les cookies peuvent expirer ou devenir invalides, nécessitant des interventions manuelles régulières. De plus, toute modification des appels réseau du site peut entraîner un dysfonctionnement du script.

Ces contraintes limitent la scalabilité et la reproductibilité du scraping à long terme, en particulier dans un cadre automatisé.

7. Conclusion et Réponse à la Problématique

Ce projet de webscraping a permis de mettre en œuvre des techniques variées de collecte de données immobilières, allant de l'exploitation d'API accessibles à des approches plus avancées basées sur le reverse engineering des appels réseau.

Il a permis de développer des compétences techniques en Python, en webscraping et en structuration de données, tout en mettant en évidence les enjeux éthiques, juridiques et méthodologiques liés à la collecte automatisée d'informations en ligne.

La comparaison entre deux plateformes aux contraintes très différentes a constitué un apport pédagogique majeur, en illustrant l'impact du contexte technique sur les choix d'architecture et de stratégie de scraping.

L'analyse révèle plusieurs éléments clés :

Marché national :

- Les **appartements** dominent le marché en volume.
- Les **studios et petites surfaces** ont un prix/m² très élevé.
- La corrélation surface ↘ prix/m² est très forte.

Paris

- Paris affiche des valeurs **hors normes**, même comparées au 92.
- Les arrondissements centraux et ouest (1er, 6e, 7e, 8e) sont les plus chers.

Île-de-France

- Le marché francilien est très contrasté :
 - 92/78 proches de Paris
 - 91/95 nettement plus accessibles

France entière

- De gros écarts entre les zones littorales, alpines, et rurales.
- La géographie reste le déterminant principal du prix au m².

Ouverture :

Une analyse complémentaire intégrant le Diagnostic de Performance Énergétique (DPE) permettrait d'affiner l'impact de la "valeur verte" sur ces prix déjà élevés.